


在线教育的过程监控与精准管理

本章概述

在线教育中的教与学行为都可以用数据的方式记录下来，分析产生的实时数据可以实现对在线教育过程的监控与精准管理。本章全面介绍在线教育如何实现对教学过程的动态监测以及通过数据挖掘实现精准的学习服务和教育管理。数据是实现过程监控与精准管理的关键，本章充分阐述大数据对在线教育的重要意义，以及基于大数据开展教与学分析的基本流程，并通过案例分析介绍大数据在教与学服务和管理中的应用潜能及发展趋势，同时阐述在此过程中教育数据标准的地位与作用。本章的主要内容包括：在线教育的数据采用与数据治理；基于大数据的个性化在线学习服务；基于大数据的精准在线教育管理与质量监测。

知识结构图



学习目标

- 能够列举在线教育数据的主要来源和类型。
- 能够列举在线教育数据采集与存储、清洗与整合的方式和工具。
- 能够叙述在线教育数据清洗的基本流程。
- 能够列举在线教育大数据的相关标准并理解其重要性。
- 能够描述基于大数据的个性化在线学习服务流程。
- 能够结合领域知识与数据科学进行学习者建模。
- 能够说出并理解学习者个性化学习方案的推荐方法。
- 分析至少两个典型的个性化在线学习服务应用案例。
- 理解在线教育管理与质量监测的目标与内容，以及基于大数据的精准在线教育管理体系的实现路径。
- 分析至少两个精准教育管理与质量监测服务的案例。

第一节 在线教育的数据采集与数据治理

一、在线教育的数据采集与存储

在线教育的数据采集与存储包括两个环节——数据采集与存储。数据采集与存储是整个学习分析过程的基础阶段，对后续流程的展开和学习分析目标的实现具有重要意义。本节内容从数据采集与存储两个方面展开介绍。

(一) 在线教育数据的采集

1. 在线教育数据采集的相关概念、原则

数据采集是对在线教育数据进行处理的第一步。在线教育数据产生，首先要完成采集工作，之后才能进行存储、清洗、整合等。数据采集的应用领域广泛。预算会计领域将数据采集定义为“把分散的、没有秩序的数据收集起来，整理成用户所需要的形式，以满足数据加工和存储等的要求”^①。在线教育应用情景下的数据采集是指根据一定的研究目标，选取不同来源和类型的在线教育数据，并借助数据采集方法和技术工具，收集成待存储和处理分析的数据。

依据在线教育平台的六大通用功能模块(课程学习模块、资源管理模块、在线讨论模块、互动问答模块、练习测试模块、总结反思模块)，在线教育数据的主要来源包括课程学习行为数据、资源管理行为数据、在线讨论行为数据、互动问答行为数据、练习测试行为数据及总结反思行为数据。^② 在线教育数据的类型既可以按照其来源进行划分，也可以按照其他标准进行分类。按照教育数据产生的环节，可分为过程性数据和结果性数据：过程性数据是在活动过程中采集到的、难以直接量化的数据(如课堂互动、在线作业、网络搜索等)；结果性数据常表现为某种可量化的结果(如成绩、等级、数量等)。^③ 按照数据的结构特征，可分为结构化数据、非结构化数据和半结构化

^① 张复英：《预算会计辞典》，2页，沈阳，辽宁人民出版社，1992。

^② 杨现民、田雪松等：《中国基础教育大数据 2016—2017：走向数据驱动的精准教学》，74～83页，北京，科学出版社，2018。

^③ 杨现民、唐斯斯、李冀红：《发展教育大数据：内涵、价值和挑战》，载《现代远程教育研究》，2016(1)。

数据。^①

对在线教育数据进行深度挖掘与分析需要有大量数据作为支撑。为了保证后续环节合理进行,数据采集作为分析过程的开端必须从数据源头坚持基本的数据采集原则。第一,目的性原则,即数据的收集需要以分析目标为导向,保证收集的数据与分析的目标高度相关。第二,科学性原则,即为保证分析结果的有用性,数据采集过程必须具备可信度与可靠性,既要获取可靠的数据来源,又要避免数据采集过程中的交叉和重复。第三,全面性原则,即在大数据时代数据的收集需要充分考虑数据的多样性,除了传统的结构化数据,还需要采集大量非结构化数据,从而有效保障分析结果的准确、可靠与科学。

2. 在线教育数据采集的技术、方法与工具

在研究目标的指导下,确定待采集分析的在线教育数据来源和数据类型后,就要按照数据采集的基本原则,选择不同采集方法,借助对应的采集技术和采集工具来完成数据采集工作。

(1) 在线教育数据采集技术

近几年在线教育蓬勃发展,在线教育数据采集技术也不断更新发展,采集工具日益多样化。在线教育数据主要由平台采集类技术进行采集,具体的技术种类主要为日志搜索分析技术、在线学习与管理平台技术、移动手机软件技术、网络爬虫技术、埋点技术,涉及各种在线与管理数据、移动学习过程数据、运维日志与用户日志数据、教育网络舆情数据等。

日志搜索分析技术:通过日志管理工具,对日志进行集中采集和实时索引,提供搜索、分析、可视化和监控等功能,最终实现线上业务实时监控、业务异常原因定位、业务日志数据统计分析、安全与合规审计。一方面,该技术可以实时监控教育设备及资产的运行状况,如设备耗电量、故障信息、安全威胁等,为智能运维提供数据支撑;另一方面,该技术可以详细记录用户的操作行为,如系统登录次数、登录时间、增删查改操作等,用于教师、学习者及管理者的行为模式诊断。

在线学习与管理平台技术:在线学习与管理平台是当前在线教育数据采集的重要载体,可以采集大多数线上学习、教研与管理活动的数据。各种在线学习与管理平台因定位和功能不同,支持采集的教育数据范围和类型也有所不同。通常情况下,在线学习平台主要负责课程学习数据的采集,如课程基本信息、课程资源、课程作业、师生交互信息、课程考核结果等。管理平台(如资产管理系统、人事管理系统等)主要负责学籍、设备资产、科研、财务、人事等信息的采集与管理。

移动手机软件技术:本质上和在线学习与管理平台技术类似,但采集渠道来自移

^① 孙洪涛、郑勤华:《教育大数据的核心技术、应用现状与发展趋势》,载《远程教育杂志》,2016(5)。

动终端,采集方式更加灵活多样。学习者可以通过无线网络,使用移动终端(智能手机、平板电脑等)与云端学习平台进行互动。通过移动终端定位技术,系统实时采集学习者的学习地点、学习时间、学习内容和学习状态等信息,服务于教师对学习情况实时监测,进而实现个性化智能辅导。

网络爬虫技术:网络爬虫又称网页蜘蛛、网络机器人,是自动下载网页的计算机程序或自动化脚本,是搜索引擎的重要组成部分。^① 该技术在数据采集领域有着广泛的应用,可以定期采集各大门户网站的数据,监控各大社交网站、博客,自动抓取企业产品的相关评论。随着互联网新媒体(如门户网站、微博、微信公众号)的兴起,教育领域的信息传播呈现传播速度快、波及范围广和内容多样化的特点。网络爬虫技术可以实时监控、采集教育领域网络舆情数据,从而为有效处理各种突发事件提供可能。

埋点技术:随着网络分析挖掘应用的不断发展而产生,分为代码埋点、可视化埋点和无埋点等方式。其基本原理是通过在网站放置相应代码或网站调用相关服务的方式,记录用户访问网站时的各类操作行为。埋点技术可以完整地记录用户的在线行为过程。

(2)常见的在线教育数据采集方法与工具

随着在线教育的发展,常见的在线教育数据采集方法有数据库直接获取、问卷调查法及网络爬虫。

数据库就是一个存放数据的仓库,这个仓库按照一定的数据结构(数据的组织形式或数据之间的联系)来组织、存储。最常用的数据库模型有两种:关系型数据库和非关系型数据库。最常见的关系型数据库产品有 MySQL 和甲骨文数据库。通过关系型数据库获取的大多为结构化数据,以二维表的方式存储。通过非关系型数据库则能获取更多非结构化数据。通过数据库直接获取的数据通常具有格式规范、结构完整的特征,但仍需要结合收集目的对数据库表结构和字段结构进行分析,以筛选抽取真正有用的数据。数据库直接获取的重点用于采集各类学习平台和学习管理系统的数据。

问卷调查法是通过制定详细周密的问卷,要求被调查者对问卷进行回答以收集资料的方法。通过设置与研究目标有关的问题编制问卷,作为数据收集的工具。网络技术的发展使电子问卷采集在线教育数据具有一定的便捷性,出现了一些电子问卷编制和发放工具,如问卷星。

网络爬虫可以分为通用网络爬虫、聚焦网络爬虫、增量式网络爬虫、深层网络爬虫四种类型。实际运用的网络爬虫系统通常是几种爬虫技术的结合。^② 对于一般小型网页数据,网络爬虫系统常常根据实际需求自主编写爬虫程序。一些成熟的网络爬虫工

① 孙立伟、何国辉、吴礼发:《网络爬虫技术的研究》,载《电脑知识与技术》,2010(15)。

② 孙立伟、何国辉、吴礼发:《网络爬虫技术的研究》,载《电脑知识与技术》,2010(15)。

具可以更便捷地抓取数据，使整个抓取过程更为简单与自动化，用户能够有条不紊且快速地抓取网页，无须编程，并将数据转换为符合其需求的各种格式。常见的网络爬虫工具如表 5-1 所示。

表 5-1 常见的网络爬虫工具

网络爬虫工具	工具特色
八爪鱼	• 分为简易模式和自定义采集模式 • 结构化格式有 ELS、TXT、HTML 和数据库 • 正则表达式工具和 XPath 配置工具精确定位万维网元素 • 可以自动识别验证码以及代理 IP 切换，有效避免网站防采集
HTTrack	• 适用于 Windows、Linux、Sun Solaris 和其他 Unix 系统 • 可以将一个站点或多个站点镜像在一起(使用共享链接) • 提供代理支持，通过可选身份验证最大限度地提高速度
Scraper	• Chrome 扩展程序，有限的数据提取功能 • 适合初学者，自动生成较小的 XPath 来定义要抓取的 URL • 有助于在线研究并将数据导出到谷歌表格 • 可以使用 OAuth 轻松将数据复制到剪贴板或存储到电子表格
Spiderman	• Java 开源万维网数据抽取工具 • 运用了 XPath、正则表达式等技术来实现数据抽取 • 微内核+插件式架构，灵活，可扩展性强，多线程保证性能

(二)在线教育数据的存储

1. 在线教育数据存储的相关概念和原则

在数据采集过程中及数据采集之后需要将数据存储起来。数据存储的应用领域多种多样，在线教育应用情景下的数据存储是指将收集的数据以一定的存储方式保存在计算机存储器中，以保证数据的完整性，同时为随时使用和加工处理做准备。

数据在数据库中存储的常见格式为字符型数据和数值型数据。用户 ID(身份标识号)、时间、资源名称等一般会存储为字符型数据，而可计量和运算的数据如资源访问次数、在线学习时长等一般会存储为数值型数据。学习行为建模过程强调分析学习者的显性和隐性在线学习行为数据，以此分析学习者的表现。^① 显性行为数据多以结构化数据的形式存储在数据管理系统中，隐性行为数据多以非结构化数据的形式存储在数据管理系统中。非结构化数据需要经过数据整合成为易于分析的结构化数据，最终集中加载进数据仓库。数据仓库是数据存储过程中的一种特殊数据存储形式，其在教育数据分析中占据重要地位。随着在线教育数据的量越来越大、更新速度越来越快、结

^① 祝智庭、贺斌：《智慧教育：教育信息化的新境界》，载《电化教育研究》，2012(12)。

构越来越复杂，数据仓库不得不融合海杜普（Hadoop）等大数据技术以更好地提供服务。^①

考虑到采集的数据可能跨越不同的在线教育平台或系统，数据存储过程需要重点关注两条原则。第一，准确性原则，即要保证采集数据的连通，要打通数据壁垒，以保证数据的唯一、准确与完整。第二，规范性原则，即在存储过程中需建立相应的存储规则和规范，为对接不同平台和系统、数据处理和分析提供规范可用的数据集。

2. 在线教育数据存储的方式和工具

在实际进行学习分析的数据存储过程中，由于分析规模和数据量的特点，往往不需要建立起完整的数据仓库。下面介绍更为常见的在线教育数据存储方式及对应的存储工具。

(1)数据库存储

结构化的数据通常直接存储在关系型数据库二维表结构中。最常见的关系型数据库产品有 MySQL 和甲骨文数据库，这两个及其他常见关系型数据库产品的特点及应用范围如表 5-2 所示。

表 5-2 常见关系型数据库产品的特点及应用范围

数据库产品	特点	应用范围
甲骨文数据库	大型关系型数据库管理系统，产品支持较广泛的操作系统平台	传统大企业、政府、金融、证券等
MySQL	中小型关系型数据库管理系统，体积小，速度快，总体拥有成本低，开放源码	互联网领域，如大中小型网站、游戏公司、电商平台等
SQL Server	大型关系型数据库管理系统，功能比较全面，效率高，只能在 Windows 系统下运行	部分企业电商、使用 Windows 服务器平台的企业
Access	入门级小型桌面数据库，界面友好，易学易用，开发简单，接口灵活，能够存取 Access/Jet、SQL Server、甲骨文数据库以及任何 ODBC 兼容数据库的资料，但性能、安全性都一般	个人管理或小型网站使用

非结构化数据通常直接存储在 NoSQL 等非结构化数据管理系统中。常见的非关系型数据库的类型、特点与典型产品如表 5-3 所示。

^① Santos L. W. , Yulia, “Data Warehouse with Big Data Technology for Higher Education,” *Procedia Computer Science* , 2017(124), pp. 93-99.

表 5-3 常见非关系型数据库的类型、特点与典型产品

非关系数据库类型	特点	典型产品
键值存储数据库	哈希表特定的键指针指向特定的数据，简单、易部署、高并发	Memcached、Redis、Memcached、Berkeley DB
列存储数据库	列族存储，应对分布式存储的海量数据	HBase、Cassandra
面向文档数据库	数据存储的最小单位是文档，同一个表中存储的文档属性可以是不同的，数据可以使用 XML、JSON、JSONB 等多种形式存储	MongoDB、CouchDB
图形数据库	使用灵活的图形模型，并且能扩展到多个服务器上	Neo4j、InfoGrid

(2)数据仓库存储

在大数据环境下，数据仓库的面向主题、集成性和时间跨度大等特点具有重要意义。数据仓库设计和建立的过程包括三步：第一，选择合适的主题，建立数据模型和数据仓库的物理设计；第二，原始库解析，通过数据采集获取原始库后，需要对表结构和字段内容进行解析，以针对数据分析目标对数据进行标记和抽取；第三，选择数据仓库技术和平台，如 Kettle 等软件工具，从操作型数据库中抽取、净化和转换数据至数据仓库。

(3)电子表格存储

对于结构简单、数据量较少的结构化数据来说，电子表格的存储功能就能够满足要求，且后续处理分析阶段的各类软件基本都支持电子表格格式的文件，例如 Excel 的工作簿和工作表是二维表结构，各个表之间无法自动建立关联，所以通常采取确定唯一标识字段和增加属性字段的方法来实现不同表数据的关联。

(4)文本存储

对于数据量较少的非结构化数据来说，直接以文本方式存储为 CSV 文件也能够满足基本的存储要求，且后续处理分析阶段的各类软件也基本都支持 CSV 格式文件，如关系网络中的关节点数据和边数据通常采用 CSV 格式来满足分析需求。

二、在线教育的数据清洗与整合

数据清洗与整合是整个学习分析过程的准备阶段，对后续流程的展开和学习分析目标的实现具有重要意义。

(一)在线教育数据的清洗

1. 在线教育数据清洗的定义和原则

目前对数据清洗尚未形成统一的定义。南京理工大学王曰芬等人给数据清洗下的定义为：清除错误和不一致数据的过程，并需要解决孤立点和元组重复问题；并不是简单地对脏数据进行检测和修正，还涉及在属性级维度的整合与分解，即数据的整合与分解。^① 数据清洗作为学习分析的关键环节之一，其目的是检测和消除数据中存在的质量问题以提升数据的质量，保证后续学习分析结果的正确性和科学性。同时，数据清洗不是完全清除错误数据，而是将其控制在不影响后续分析结果准确性的程度之内^②，在最大程度上保持数据的真实性，避免信息的丢失。

数据清洗对于在线教育数据分析与挖掘的重要性不言而喻，在进行数据清洗时必须满足数据特性，完成数据清洗的基本环节等。数据特性包括：①一致性，指关联数据在不同的存储位置或数据获取时间上的一致程度，表现为数据存在关系、等值关系、逻辑条件关系等保持一致；②完整性，指数据的完整程度，具体表现为数据库整体结构的完整程度、数据集中对象的完整程度、数据表中的字段在表的功能结构上的完整程度、数据参照表的完整程度、不同的数据表之间引用关系的完整程度；③有效性，指各数据项的值在合理的取值范围之内，采用统一标准的定义方式，在一段时间内数据分析应用价值较高，满足时效性。在线教育数据清洗包含五个步骤，如图 5-1 所示。




图 5-1 在线教育数据清洗的五个步骤

2. 在线教育数据清洗的工具

目前市场上专门进行数据清洗的工具较多，一些通用工具也有部分数据清洗的功能，如 Excel、SPSS，但当数据量太大时，如当 Excel 处理超过 100 万条数据时，通用工具就会出现卡顿、运行超时等问题，因此有必要寻求一些专门的工具。下面介绍在线教育数据清洗的一些主流工具。

(1) OpenRefine

OpenRefine，原名 Freebase Gridworks，是一款具有数据画像(使用统计方法发现数据的结构、内容、质量，预发现包含的错误信息)、清洗、转换等功能的工具。OpenRefine 的数据分析和清洗功能主要包括：数据排序、数据透视、简单单元格转换、

^① 王曰芬、章成志、张蓓蓓等：《数据清洗研究综述》，载《现代图书情报技术》，2007(12)。

^② 潘玮、牟冬梅、李茵等：《关键词共现方法识别领域研究热点过程中的数据清洗方法》，载《图书情报工作》，2017(7)。

数据类型转换、移除重复行、处理多值单元格、相似单元格聚类、单元格值转换、增加源列、行列转换。

OpenRefine 的优点有：免费；可以导入和导出多种格式的数据，如标签或逗号分隔的文本文件以及 EXL、XML、JSON 文件；在数据导入的时候，可以根据数据类型将数据转换为对应的数值和日期型等；可以根据单元格字符串的相似性来聚类，并且支持关键词碰撞和近邻匹配算法；在单元格值替换时，能够对表达式进行出错的处理，如保留原值、置空或使用错误值；可以控制表达式运行的次数；提供排序和筛选等分析功能；基于 Java 环境，可以方便地使用正则表达式查找需要的字段或数值。

OpenRefine 的缺点有：虽然 OpenRefine 像 Excel，但无法实现电子表格的计算功能，因此涉及计算时需要将数据导出来；如果数据集较大，OpenRefine 给出的建议可能会很多，需要花时间来检查是否接受其建议；OpenRefine 并不提供传统意义上的两个数据集之间的关联查询和处理，如 MySQL 中的 join 操作等。

(2) Kettle

Kettle 是构建数据集成解决方案的 ETL(抽取—转换—加载)工具，也是 ETL 的一种开源工具，纯 Java 编写，可在 Windows、Linux、Unix 上运行。Kettle 能够对不同格式的数据进行接收和输入，包括 XML、Access、Cube、Excel 等。接收数据后，Kettle 可以在相应的法则下进行源数据结构分析、清洗及解码，最后实现数据的整合。^① Kettle 有三个主要组件——Spoon、Kitchen、Pan。Spoon 是一个图形化界面，Kettle 的帮助文档可以在 Spoon 中找到。

Kettle 的优点有：容易上手，部署简单；数据抽取高效稳定，在数据转换、处理中应用较多，拥有良好的插件扩展功能，支持集群操作；允许管理来自不同数据接口的数据，通过提供一个图形化的用户环境来描述用户想做什么，而不是用户想怎么做；支持很多种输入和输出格式，包括文本文件、数据表及数据库引擎。

Kettle 的缺点有：数据处理速度较慢；在数据捕获方面，对数据库进行实时监控时，Kettle 通常采用 CDC(变化数据捕获)方式，需要部署在核心数据库服务器上，会对核心数据库造成一定压力；由于是开源软件，因此不可避免地存在性能瓶颈、中文支持等问题。

(3) DataCleaner

DataCleaner 是一个基于 Java 环境的数据质量分析、比较、验证和监督软件，主要用于主数据管理(master data management, MDM)。MDM 解决的问题就是数据的质量，如清除重复条目、解决用户数据填充方式不同等问题。DataCleaner 进行数据清洗需要用到的组件有空值过滤器、完整性分析仪、日期间隔分析器、参照完整性、唯一

^① 王曰芬、章成志、张蓓蓓等：《数据清洗研究综述》，载《现代图书情报技术》，2007(12)。

键检查、键值分配/频率分析、键值匹配等。

DataCleaner 的优点是可以访问几乎所有数据库，包括甲骨文数据库、MySQL、dBASE 等。其缺点则是收费。

(4) DataWrangler

DataWrangler 是一款由斯坦福大学开发的在线数据清洗、数据重组软件，用现行的阿尔法码编写，但阿尔法码还在改进中。DataWrangler 的核心功能包括去除无效数据、提取部分数据、自动填充数据、删除无用数据、数据重构。与传统的数据处理软件相比，其独特的智能分析和建议功能极大方便了用户的数据处理操作。DataWrangler 还会列出数据修改的历史记录，用户可以极为方便地查看过去的修改，并可以撤销某一条修改操作。

DataWrangler 的优点有：文本编辑非常简单；是一款在线工具，省去了安装软件的烦琐过程，也摆脱了操作系统对软件使用的限制。

DataWrangler 的缺点有：建议功能虽然强大，但某些时候的建议是无用的，或者很难理解；由于 DataWrangler 是基于网络的服务，必须把数据上传到外部网站，不适合敏感的内部数据。

(二) 在线教育数据的整合

1. 在线教育数据整合的定义和原则

数据整合是把不同数据源的数据在收集、整理、清洗、转换后加载到一个新的数据源，为数据消费者提供统一数据视图的数据继承方式。数据整合和数据集成的区别在于数据集成涵盖的范围比数据整合广。数据整合的核心任务是将互相关联的分布式异构数据源集成到一起，使用户能够透明地访问这些数据源。

对在线教育数据进行整合有利于消除在线教育发展过程中的数据孤岛现象。对在线教育数据进行整合必须考虑到可能出现的问题，遵循数据整合的基本原则：第一，模式集成与对象匹配问题；第二，冗余问题；第三，数据值冲突的检测与处理问题；第四，数据变换问题。

2. 在线教育数据整合的工具

在线教育数据整合常用的工具有：Kettle、Informatica、Datastage、ODI、OWB、DTS、HaoheDI、Teradata。可以根据对平台的支持程度、对数据源的支持程度、数据转换和加工功能、继承性和开发性来选择合适的工具。下面介绍其中一些工具。

(1) Datastage

Datastage 是 IBM 公司开发的一款数据集成软件平台，能够帮助企业从散布在各个系统的复杂异构信息中获取更多的价值。

Datastage 的优点是简单易用。相较于 Informatica 和 Kettle，Datastage 的所有操

作都在同一界面，不用切换界面就能够看到数据的来源，而且数据处理速度较快。但 Datastage 部署比较麻烦。

(2) Informatica

Informatica 是全球领先的独立企业数据集成软件提供商。分布在世界各地的很多组织机构都依赖 Informatica 为其重要业务提供及时、相关、可信的数据，从而赢得竞争优势。全球众多知名企业依靠 Informatica 使用及管理其在本地、云和社交网络上的信息资产，以挖掘信息潜能，并达到卓越的业务目标。

Informatica 的优点为简单易用，且数据处理速度较快。但对数据的操作无法撤销。使用 Informatica 时需要安装客户端和服务端。

三、在线教育大数据标准

在教育信息化推进的过程中，在线教育大数据存在数据互通低效、协同困难和拓展受限等诸多问题，而在线教育数据的标准化对于解决上述问题具有基础性和引领性作用，对于规范在线教育相关产业发展也有现实意义。本节内容对国内外在线教育大数据相关标准进行梳理，以展现在在线教育大数据相关标准的研制情况及其对发展在线教育大数据的重要性。

(一) 国外在线教育大数据相关标准

1. ISO / IEC JTC 1 标准

截至 2019 年 10 月，国际标准化组织国际电工委员会第一联合技术委员会 (ISO/IEC JTC 1) 协同 16 个参与国及 25 个观察国，制定了包括大数据基本概念和重要术语的《大数据——概述和术语标准》(ISO/IEC 20546)，以及包括用户视图和功能视图的《大数据参考架构——第三部分：参考架构标准》(ISO/IEC 20547-3)，其大数据分析框架如图 5-2 所示，为在线教育大数据的标准化工作提供了重要参考。

2. ITU-T Y. 3600

在国际电信联盟 (ITU) 范围内，大数据标准主要由电信标准化部门 (ITU-T) 发起和推进，有 10 个相关研究组。其中，最活跃的是第 13 学习研究组 (SG13)，其研究主题聚焦于包含移动和下一代网络在内的未来网络。2015 年 11 月，ITU-T 发布《基于云计算的大数据需求与能力标准》(ITU-T Y. 3600)，详细规定了以云计算为基础的大数据需求、能力和使用案例，并设计了大数据情境模式 (如图 5-3 所示)。此外，SG13 还发布了《大数据——数据交换的框架和需求标准》(ITU-T Y. 3601)，并且正在研制《大数据——数据集成的概述和功能需求》和《大数据——元数据框架与概念模型》等大数据相关标准。




图 5-2 ISO/IEC JTC 大数据分析框架




图 5-3 ITU-T Y. 3600 大数据情境模式

3. NBD-PWG 大数据参考框架

美国标准及技术研究所(NIST)为响应白宫提出的大数据研究国家战略¹²，同时满足市场需求，于2013年6月成立大数据工作组(NBD-PWG)。NBD-PWG的重点是联合工业界、学术界和政府，形成大数据的定义、术语、安全参考体系结构和技术路线图。NBD-PWG 大数据参考框架如图 5-4 所示。

(二)国内在线教育大数据相关标准

1. 相关标准研制进展

在通用大数据标准研制方面，一方面，我国积极参与国际标准组织关于 ISO/IEC 20546 和 ISO/IEC 20547-3 的研制工作。另一方面，我国于 2014 年成立全国信息技术标准化技术委员会大数据标准工作组，开展《信息技术 大数据 技术参考模型》《信息技




图 5-4 NBD-PWG 大数据参考框架

术 大数据 术语》等十多项国家大数据相关技术标准研制工作。

在教育大数据标准研制方面，全国信息技术标准化技术委员会教育技术分技术委员会(CELTC)于 2017 年成立教育大数据标准工作组，推进教育大数据标准的研制，包括《信息技术 学习、教育和培训 教育大数据标准框架》《信息技术 学习、教育和培训 教育大数据互操作接口服务规范》《信息技术 学习、教育和培训 教育行为数据框架、模型与元数据》《信息技术 学习、教育和培训 教育大数据存储服务规范》《信息技术 学习、教育和培训 课堂教学行为编码规范》《信息技术 学习、教育和培训 基础教育 学习者刻画/画像》《信息技术 学习、教育和培训 教师刻画/画像》《信息技术 学习、教育和培训 学校刻画/画像》等。

2. 大数据标准体系

中国电子技术标准化研究院、全国信息技术标准化技术委员会大数据标准工作组在 2018 年联合发布了《大数据标准化白皮书(2018 版)》，提出了大数据标准体系框架，由基础标准、数据标准、技术标准、平台和工具标准、管理标准、安全和隐私标准、行业应用标准七个类别的标准组成，为不同领域大数据标准的制定提供了指导，尤其为教育大数据标准化工作的开展指明了方向。

基础标准：为整个标准体系提供包括总则、术语、参考模型等基础性标准。

数据标准：主要针对底层数据相关要素进行规范，包括数据资源和数据交换共享两部分，其中数据资源包括元数据、数据元素、数据字典和数据目录等，数据交换共享包括数据交易和数据开放共享。

技术标准：主要针对大数据相关技术进行规范，包括大数据集描述及评估、大数据处理生命周期技术、大数据开放与互操作、面向领域的大数据技术四类标准。

平台和工具标准：主要对大数据相关平台和工具进行规范，包括系统级产品和工具级产品两类。

管理标准：作为数据标准的支撑体系，管理标准贯穿于数据生命周期的各个阶段，主要是对数据管理、运维管理和评估三个层次进行规范。

安全和隐私标准：作为数据标准体系的重要部分，安全和隐私标准贯穿整个数据生命周期，既关注传统的数据安全和系统安全，又关注基础软件安全、数据分类安全等。

行业应用标准：主要是针对大数据为各个行业所能提供的服务制定的规范，包括教育、政务、服务等领域。

根据大数据标准体系框架，发布、报批、在研以及拟研制的大数据领域国家标准共有 94 项，这些标准可极大地促进教育领域的大数据标准化工作，为消除教育系统“数据孤岛”现象奠定基础。

3. 教育大数据标准体系

教育大数据标准化工作的开展是国家教育信息化发展的战略需要，是教育大数据平台建设的技术需要，是教育主体智能发展应用的需要。CELTC 副主任委员吴砥及其团队在借鉴大数据标准体系框架的基础上，融合教育发展需求，划定了教育大数据标准体系的层次结构(如图 5-5 所示)，并明确了各模块及内容间的相互关系，使各项标准与规范有机结合，为在线教育大数据开发利用提供重要支撑，为促进在线教育平台互联互通和实现在线教育数据全生命周期管理提供基础保障。^①




图 5-5 教育大数据标准体系

(1) 教育大数据基础类规范

教育大数据基础类规范是教育大数据标准的基础性、通用性规范，用以支持教育

^① 吴砥、饶景阳、吴晨：《教育大数据标准体系研究》，载《开放教育研究》，2020(2)。

大数据标准体系其他标准的复用。其中,术语规范主要明确教育大数据标准体系涉及的术语定义、符号说明和术语解释;架构规范旨在通过对标准体系整体结构及相互引用关系的描述,提供结构化、易于管理、便于实施且可扩展的标准框架;接口规范旨在为教学、管理和服务平台之间业务复用提供基础接口调用与交互规则;绑定规范规定各类教育信息模型 XML 语言描述语法;实践指南是指导构建和利用教育大数据标准的指导性文件,规定教育大数据标准体系各项标准的应用领域、使用场景和使用方法。

(2) 教育大数据管理类规范

教育大数据管理类规范包括数据管理规范、平台管理规范和过程管理规范。数据管理规范规定教育数据开放和共享的基本策略,定义开放共享数据的知识领域、敏感程度和开放权限,为数据开放程度定级和元数据结构设计提供参考。平台管理规范规定教育大数据平台有形和无形的运营支撑环境,提高教育大数据平台运行的兼容性。过程管理规范规定对教学活动中各重要过程节点的管理,包括定义和管理不同时空尺度的教学过程信息及教学过程间的关联关系。

(3) 教育大数据数据类规范

教育大数据数据类规范是教育大数据标准体系的核心,主要包括资源数据、对象数据和行为数据的相关规范。

资源数据类规范定义各类教育资源的组织方式,包括资源编列规范、资源元数据规范和资源封装规范。资源编列规范规定各类教育资源的编码规则,确保开放共享教育资源标志的唯一性,便于教育数据的大范围分发和应用;资源元数据规范规定各类教育资源的描述方法;资源封装规范定义各类教育资源互操作所需要的数据结构以及教育资源统一的包装规则,支持教育资源在教育平台之间的传输、复制、买卖和分发。

对象数据类规范包括教师画像、学生画像和学校画像。教师画像规定教师对象的信息模型和要素,包括教师的基本信息、教学活动组织信息、教学资源创建信息、教学效果评价信息等。学生画像规定学生对象的信息模型和要素,包括学生的身份标识、学力定义、学习风格、学习能力、知识掌握程度、学习偏好等。学校画像规定学校对象的信息模型和要素,包括学校的基本信息、办学条件信息、师资力量信息、学生结构信息、办学水平信息等。

行为数据类规范包括教学行为、学习行为、管理行为和教研行为方面的数据规范。其中,教学行为数据规范规定有效教学行为的界定方法和特征,并定义各类教学行为的信息模型和数据结构。学习行为数据规范规定学习行为要素、分类和数据模型,定义学习行为数据记录框架。管理行为数据规范规定教育管理过程的维度和特征,并定义管理行为数据模型和数据结构。教研行为数据规范规定教研行为的行为要素和分类方法,并定义教研行为的数据模型和数据结构。

(4)教育大数据支撑技术类规范

教育大数据支撑技术类规范包括数据采集规范、数据建模规范、数据处理规范、数据存储规范、数据分析规范、数据互操作规范、数据接口规范和数据可视化规范。数据采集规范规定教育数据的采集类别、采集指标、采集频率和采集要求等信息。数据建模规范规定各类教育数据的抽象组织结构,确定数据库中数据的组织形式等。数据处理规范规定教育数据录入、审核、修改、提交和汇总的操作规范。数据存储规范规定教育大数据在存储介质中的存储与交换方法。数据分析规范规定对复杂教育过程逐渐拆分处理的判断标准和分析范式,以实现复杂教育过程的深入理解。数据互操作规范规定不同教育平台之间以及不同教育环节之间数据交互操作的语法与语义。数据接口规范规定教育平台之间业务数据传输格式,方便系统平台之间业务数据的共享与交换。数据可视化规范规定教育数据可视化的基础图形元素和表现形式等,定义教育数据可视化设计语言的语法与语义。

(5)教育大数据应用类规范

教育大数据应用类规范涵盖差异化教学、个性化学习、协作化教研、精细化管理、智能化服务和过程化评价六大类规范。差异化教学规范规定教师将时间、精力和教学素材等资源差异化地分配给不同背景、基础、技能水平和兴趣的学生,以促进促进学生成长的教学模式标准。个性化学习规范规定学生依据个体特征、个体需求和个体差异,开展自主学习活动的学习行为标准。协作化教研规范规定校际协作参与教学经验总结、教学问题发现和教学方法研究的教研模式标准。精细化管理规范规定学校对教育教学各环节制定的制度、规程和评价指标的管理模式标准。智能化服务规范规定教育系统通过捕捉教育用户的访问信息,结合先验知识,构建需求模型,主动推送优质教育资源的教育服务模式标准。过程化评价规范规定教学和管理效果的过程化评价模式标准,支撑教育过程的实证分析。

(6)教育大数据安全类规范

教育大数据安全类规范包括隐私保护规范、权利保护规范和访问控制规范。隐私保护规范规定对教育用户隐私信息和教育领域敏感数据的保护措施。权利保护规范规定教育主体拥有获得与自身相关的全部教育信息和数据的合法权利,保护教育数据的分层分级合理利用。访问控制规范规定教育大数据的访问控制机制,制定教育主体对教育数据的访问控制规则。



教学活动建议

本节教学内容的重难点是在在线教育的数据采集与存储以及数据清洗与整合,需要学习者有计算机等方面的知识基础。如果学习者已有相关基础,建议教师在系统讲解的基础上带着学习者体验一些工具。如果学习者没有相关知识基础,建议教师通过视

频资源与专家报告相结合的方式的教学，重点放在原理阐述，不侧重于技术实现方法。



学习活动建议

本节学习内容涉及跨学科知识，建议学习者利用网络，并咨询大数据技术、教育技术领域专家，全面理解数据方面的原理性知识，同时积极探究、体验相关工具。

第二节 基于大数据的个性化在线学习服务

一、个性化在线学习服务的实现流程

随着大数据技术不断成熟发展，在线学习越来越个性化和精准化。在线学习海量数据的生成为绘制学习者画像、精准建模提供了条件，有利于发现学习者的学习优势、学习薄弱点等。本节以个性化适应性学习为核心，梳理基于大数据的个性化适应性学习的实现流程。

(一) 个性化适应性学习概述

个性化适应性学习是指基于学习者个性特征差异提供个性化学习服务，记录、挖掘和深入分析学习行为历史数据，以可视化方式呈现数据结果，用于评估学习过程、发现潜在问题和预测未来表现，并进行个性化干预、指导，促进有效学习的发生。^① 目前，经过几年的摸索，关于个性化适应性学习已经有了一些成熟的做法与实践案例，取得的效果得到了较广泛的认可，典型平台有 Knewton、Smart Sparrow、DreamBox Learning、猿题库、作业帮、一起作业网等。

(二) 基于大数据的个性化适应性学习过程

基于大数据的个性化适应性学习利用协同过滤技术实现向学习者推送与其有相同或相近兴趣偏好特性学习者的学习信息，即整个学习过程既可实现学习者控制学习、自我调节学习、教师个性化干预指导，又可实现系统根据用户特征适应性推送物化资源

^① 杨现民、田雪松：《互联网+教育：中国基础教育大数据》，112~115页，北京，电子工业出版社，2016。

以及具有相似学习兴趣偏好的学习者信息，其学习过程如图 5-6 所示。^①




图 5-6 基于大数据的个性化适应性学习过程

基于大数据的个性化适应性学习过程由七个环节组成，充分说明学习者可实现学习的途径和方法。

在图 5-6 中，通过环节①④⑤⑥可以实现学习者根据仪表盘中的可视化信息（如学习者特征、学习结果、学习需求等）进行自组织学习，制订并执行学习计划，自主选择学习策略、学习资源，对学习进行自我评估，有助于提高学习者的学习能动性和主动性。

通过环节①②③，系统可采用贝叶斯网络、项目反应理论、费尔德-西尔弗曼学习风格模型及霍夫斯坦德文化模型等判定学习风格、兴趣偏好、知识水平、学习文化等学习者特征，适应性呈现个性化、可视化的学习路径、学习资源、同伴信息、工具等，有助于提升学习者的自我效能感。

通过环节①②④⑤⑦，教师、管理者可以根据信息面板中的可视化信息调整教学策略，实施个性化指导和教学干预，有助于掌握学习者的学习规律、优化学习过程、

^① 姜强、赵蔚、王朋娇等：《基于大数据的个性化自适应在线学习分析模型及实现》，载《中国电化教育》，2015(1)。

改进学习效果、提升教育质量。

二、基于领域知识和数据科学结合的学习者建模

模型是大数据应用科学化、精准化、可干预的核心基础。领域知识的介入和数据科学的结合是大数据时代学习者建模的必经之路。下面对基于领域知识和数据科学结合的学习者建模的概述、流程、方法及应用场景进行详细阐述,以深度理解大数据时代学习者建模的重要性与意义。

(一) 基于领域知识和数据科学结合的学习者建模概述

1. 相关概念

领域知识起源于人工智能领域,指在某一个领域内概念之间的相互关系和有关概念的约束的集合,具有知识本身所有属性的特点。^①美国教育心理学家亚历山大在总结知识表征分类后提出,领域知识是指个体所拥有的关于某个特定领域的知识,包括陈述性知识、程序性知识和条件性知识三部分。^②

在大数据时代,数据不仅是科学领域研究的成果,而且是科学研究的重要基础。随着数据越来越受到重视,学界对数据科学的探讨逐渐兴起。从不同的视角出发,数据科学有不同的含义,但基本具备两个主要内涵:一是针对数据本身,研究数据的各种类型、状态、属性及变化形式和规律;二是为自然科学和社会科学研究提供一种新的方法——科学研究的数据方法,其目的在于揭示自然界和人类行为的现象和规律。^③

学习者模型源于智能计算机辅助教学(ICAI)理论,是与在线学习相关且随着智能在线学习兴起而快速发展的一个重要理论。学习者模型是对真实学习者的一种抽象表示,代表学习者的知识技能、认知行为、情感体验等方面的水平和特征。^④

2. 领域知识和数据科学在学习者建模中的关键作用

大数据建模也叫数据挖掘,数据挖掘涉及数据采集、数据管理、数据分析、数据建模和数据应用等过程,需要充分运用数据科学的方式方法。数据采集和数据管理通常由数据工程技术专家完成;数据建模由数学与统计学专家完成;数据分析涉及领域知识的问题,领域知识是沟通大数据处理的核心环节。因此,结合领域知识与数据科

^① Dhondt M., Dhondt T., “Is Domain Knowledge an Aspect”, *Workshop on Object Oriented Technology*, 1999, pp. 293-294.

^② Alexander P. A., Schallert D. L., Hare V. C., et al., “Coming to Terms: How Researchers in Learning and Literacy Talk About Knowledge”, *Review of Educational Research*, 1991(3), pp. 315-343.

^③ 朱扬勇、熊赞:《数据学》,12页,上海,复旦大学出版社,2009。

^④ Chrysafiadi K., Virvou M., “Review: Student Modeling Approaches: A Literature Review for the Last Decade,” *Expert Systems With Applications*, 2013(11), pp. 4715-4729.

学方式方法在建模过程中能够帮助识别教育大数据的用途,帮助建立正确的学习者模型,帮助处理数据分析样本,从而保证数据分析结果的准确性,进而实现学习者模型构建的科学性和精准性。

(二)基于领域知识和数据科学结合的学习者建模流程

目前来看,学习者建模有两个取向:一是把行为数据聚合成特征变量,以特征变量为核心开展数据监测服务,从而通过特征值挖掘相应的行为规律,最终为有效干预提供支撑;二是通过教育教学理论建立某个教与学变量,并且基于理论建模和数据科学形成从底层数据到特征值再到教与学变量的数据指标聚合,从而使学习分析结果的可阅读性和可干预性更强。^①这里以郑勤华等人提出的学习者综合评价参考模型(S-SERI模型)为例阐述基于领域知识和数据科学结合的学习者建模流程,即自上而下构建理论模型和自下而上构建算法模型。^②

1. 学习者模型之理论模型构建

理论模型构建是自上而下的,首先确定模型类型,然后形成模型下的维度,最后为每个维度选择合适的指标。在结构上,一个理论模型包含多个维度,每个维度包含多个指标,指标有时也包含多个数据项。

郑勤华等人运用理论演绎和专家访谈法,在加涅的目标分类基础上,根据在线学习特征及在线学习者(主要是成人学习者)的特点,构建了S-SERI模型(如图5-7所示)。S-SERI模型由维度和指标构成,其中维度满足对学习者某方面评价的需求,具有一定概括度和抽象层次,可能包含多个指标。指标则是对维度的具体分解。例如,衡量学习者在线学习的“投入度”维度包括“认知投入”“情感投入”“行为投入”三个指标。维度和指标的确立主要基于两个原则:一是典型性原则,评价指标应选取最能反映学习者在评价目标上发展水平的典型特征;二是可操作性原则,各维度一级级分解成的最终指标应该是具体的,可以观察、描述和测量。

(1)投入度

从活跃性、持续性等方面对学习者在在线学习的投入程度进行评价。对投入度的评价除行为投入外,还包括更深层次的认知投入及情感投入。投入度是对学习者学习过程进行表征的重要维度。

(2)主动性

包括完成自主学习任务的主动性、参与强制活动的主动性及进行交互的主动性。

^① 郑勤华、孙洪涛、陈耀华等:《基于学习分析的在线学习测评建模与应用——综合建模方法研究》,载《电化教育研究》,2016(12)。

^② 郑勤华、陈耀华、孙洪涛等:《基于学习分析的在线学习测评建模与应用——学习者综合评价参考模型研究》,载《电化教育研究》,2016(9)。




图 5-7 S-SERI 模型

主动性可在一定程度上表现学习者的学习动机水平与变化情况。

(3)调控度

从学习的规律性、持续性、学习效率三方面对学习者的学习过程的水平进行评价，调控度是对学习者认知策略、自主学习能力进行表征和评价的重要维度。

(4)完成度

以课程的教学目标为标准对学习者的实际完成情况进行评价，不同类型课程的教学目标侧重点不同，完成度的指标及权重设置也会有相应的调整。

(5)联通度

对学习者的建立社会化认知网络的能力进行评价，包括建立连接的能力、维护连接的能力等。联通度的评价核心是交互，包括学习者与资源的交互、学习者与教师及学习同伴的交互。

2. 学习者模型之算法模型构建

郑勤华等人在构建 S-SERI 模型时指出，由于维度建模源自理论演绎和专家访谈，下一步的重点是将构建的维度模型进一步细化，并提炼出相应的数学结构，从而为量化评估提供可操作的依据。

理论模型构建是自上而下的，而算法模型的构建是自下而上的，即先确定各维度下最底层指标的计算方法，再将这些指标进行聚合，最终得到维度算法模型，模型构建的具体流程如图 5-8 所示。

(1)原始数据汇聚与预处理

学习者的原始学习数据往往是多源异构的，分散存储在内容管理系统、学习管理系统、教务管理系统等各系统中。将这些数据汇聚到一起并尽可能地对学习者的学习过程进行还原是科学和全面评价的基础。这就要求对各个平台的数据有一个全面完整的认识，理顺数据中的业务逻辑，提取在线教育各类业务工作中的关键主体、要素和流程。业务所涉及的流程是相互交织的一系列复杂过程，包含多种动态和静态信息。流程往往体现了要素的状态变化和过程。在此基础上，需要将在在线教育的核心教




图 5-8 S-SERI 模型构建具体流程

学与管理业务分解，形成覆盖学习者学习过程的完整数据描述。

之后，参考 xAPI 的理念，基于业务解析提取出关键学习主体、要素和流程，进一步构建基于学习的活动流。活动流由必要属性和可选属性构成：必要属性包括活动主体、动作及活动对象三类；可选属性包括活动时间、活动结果等若干类。通过这些属性可以对学习者的学习活动过程进行描述，如××(活动主体)在××时间(活动时间)观看了(动作)关于××知识点的视频(活动对象)。表 5-4 列出了一些可能的必要属性，在不同教学设计、教学情境中，这些属性需要做出一定调整。

表 5-4 活动流中一些可能的必要属性

活动主体	动作	活动对象
教师、学习者、小组	浏览、观看、编辑、评论、提问、回答、笔记、分享、标注、创建、收藏、取消收藏、得分、下载、发表、回复、搜索、删除、参与、尝试、暂停、继续、跳过、完成、退出、通过、失败	文件、问题、协作、视频、页面、讨论、作业、消息、笔记、学习计划、测试、档案、模块

构建基于学习的活动流可以方便不同数据源按照统一的规范进行整合，提高数据汇聚的效率。按照这种规范描述的学习过程最终会以具有语义结构的数据进行存储，也便于机器理解和学习。同时，由于学习分析主要基于行为数据进行，对数据预先进行基于(行为)活动的描述和封装有助于后续研究的进行。

在解析业务方面，学习活动数据化的过程会遇到数据质量问题。当前在线教育的数据质量整体水平比较低，缺失比例较高，可能出现异常值、不确定的定义和编码、无效或错误的的数据以及数据不一致等情况。在这个阶段要及时地发现数据质量存在的问题，对数据进行清洗，尽可能提高数据质量，为后续的分析奠定基础。

(2) 潜在变量生成

潜在变量是指从原始数据库中获得的在意义上与模型可能相关的变量。这些变量与评价需求相关,而且数据质量较好。潜在变量的生成是在之前数据汇聚的基础上,提取出能够描绘学习活动核心要素和流程的关键数据,这些数据是后续模型构建的基础。原始数据汇聚阶段的数据集合是对教学活动和学习者学习经历的完整描述,潜在变量则是在此基础上进行提炼的结果,是一系列能够表征教学与学习情况的有效标准数据项。

潜在变量生成阶段仅通过对机构教学要素和教学流程的分析得出有效的数据项,应尽量避免复杂计算。如必须进行复杂计算,则只有通用性的、能够对机构的教学与管理起到重要监测作用的变量才可以被纳入潜在变量。这些数据项可以是基本的属性量,也可以是行为计数,还可以是简单计算的结果,在少数情况下可以是需要较为复杂计算的结构,如教学交互的有效性等。

(3) 特征变量选取

特征变量是从潜在变量中选出的,统计分析证明具有足够好的数据质量,可以进一步进入算法构建的变量。特征变量选取又称特征工程,根据具体的评价指标,用特定领域知识或数据科学的方法来选择、删除、组合潜在变量得到特征变量,作为指标的计算变量。之所以需要进行特征变量选取,是因为多余的变量会对模型训练产生干扰,有可能造成模型的过拟合。另外,在数据体量越来越大的情况下,变量过多会大大降低模型的训练和计算效率。

特征变量与评价指标有较大不同,它是评价指标构建的基础,可以通过不同类型的计算成为监测教学与管理状态的重要指标。当需要计算的指标较为简单、潜在变量较少时,可以让专家基于特定的领域知识来人工选取特征变量。在指标算法复杂,涉及较多变量的情况下,人工的方法存在一定的局限性,可能影响指标算法的准确性,所以应综合采用以下几种方式来选取特征变量。

第一,计算变量与对应指标的相关性,选择与指标有相关性的变量作为特征变量。第二,将潜在变量组合后再选择特征变量,如对学习者的人口学数据(性别、年龄、前置学历等)进行组合,获得较大的特征集,组合特征能够同时兼顾全局模型和个性化模型。第三,在数据构造较为复杂的时候可以采用深度学习的方法来自动识别特征变量,深度学习又被称作无监督特征学习,具有自动学习的能力,可以从大规模未标注数据中凸出学习数据的本质特征。

维度值和特征变量的关系如表 5-5 所示。表 5-5 并没有列出所有特征变量。特征值都有两个数值,一是原始特征值,如学习频次,某个学习者以周为单位的学习频次是 15 次,那么记录的特征值就是 15。二是百分制数值,因为综合评价需要将特征值聚合成维度值,所以需要将原始特征值转换为百分制,一般通过聚类、Z 分数、逻辑回归等方法将特征值加以转换,如学习频次 15 转换为百分制为 90。

表 5-5 维度值与特征变量的关系

投入度	V1 学习频次		V2 学习时长		V3……	
	原始特征值	百分制数值	原始特征值	百分制数值	原始特征值	百分制数值
主动性	V1 回答问题频次		V2 论坛发帖频次		V3……	
	原始特征值	百分制数值	原始特征值	百分制数值	原始特征值	百分制数值
调控度	V1 作业提交延迟时间		V2 单次视频学习时长		V3……	
	原始特征值	百分制数值	原始特征值	百分制数值	原始特征值	百分制数值
完成度	V1 视频完成率		V2 作业完成率		V3……	
	原始特征值	百分制数值	原始特征值	百分制数值	原始特征值	百分制数值
联通度	V1 社交活跃度		V2 社交参与度		V3……	
	原始特征值	百分制数值	原始特征值	百分制数值	原始特征值	百分制数值

(4)模型构建

指标算法构建主要有两种类型：一种是通过问卷、量表或其他测量方法获得指标因变量的值，在这种情况下采用有监督的机器学习(如人工神经网络或一些分类算法)，通过调整参数进行模型训练，选择准确度较高的算法即可；另一种主要是通过机器学习方法对指标进行分析，在这种情况下需要先将专家知识通过某种方式传授给机器，再由机器完成专家所不能够完成的整合分析。例如，对学习者的活跃度这个指标进行分析时，可以找到在线时长、登录次数等特征数据，专家对不同活跃水平的学习者贴标签，然后对各类学习者进行聚类等各种分析，并对分析的结果进行初步的模型计算；接下来根据计算结果，确定学习者活跃度的分析算法；两种类型的指标算法确定以后，采用专家模糊层次分析和机器学习相结合的方法确定各个低一级指标的权重，最后一步步向上聚合成更高级别的指标、维度，最终构建 S-SERI 模型。

(5)模型验证迭代

模型的信度和效度是重要的衡量指标。除一般性数据挖掘指标外，需要将其同业务数据进行对比，并根据平台当前的数据情况确定其置信区间。模型构建需要多轮迭代，需要尝试各种特征变量的组合与各种不同类型的模型计算方式的结果，通过比较计算结果最终确定模型算法。

(三)基于领域知识和数据科学结合的学习者建模方法

作为建模流程的指南，建模方法是完成学习者建模的重要内容。图 5-9 展示了学习者建模的开发流程，以及领域专家和数据科学方式方法在流程中各环节的位置和作用。在实际研究与实践中，因建模目标不同，学习者建模的流程、方法略有差异。




图 5-9 基于领域知识和数据科学结合的学习者建模开发流程

这里以郑勤华等人提出的在线学习综合测评模型的构建方法为例，以其建模流程为线索，通过关于评价的核心问题、综合建模过程中的特征工程、模型构建中的应用迭代三个层面来阐释学习者建模的方法。^①

在线学习综合测评模型的构建从教育学规律和数据的聚合两个角度相向而行，形成同时保证科学性与可行性的模型解决方案，具体的构建流程如图 5-10 所示。




图 5-10 在线学习综合测评模型的构建流程

^① 郑勤华、孙洪涛、陈耀华等：《基于学习分析的在线学习测评建模与应用——综合建模方法研究》，载《电化教育研究》，2016(12)。

1. 关于评价的核心问题

(1) 评价对象

评价对象主要依据评价服务的需求来确定。评价对象既可以是学习者，也可以是学习；既可以是学习者的某个方面，也可以是学习的某个特征。在“基于学习分析的在线学习测评建模与应用”系列研究中，郑勤华等人分别以学习者、教师、课程为评价对象进行了探索性研究。之所以选这三者，是因为它们是在线学习最核心的主体，适应性服务基本都围绕这三者展开。

(2) 评价维度

评价维度是重点也是难点。郑勤华等人以投入度、主动性、调控度、完成度、联通度这五个维度进行了综合建模。之所以选择这五个维度，一方面是因为评价的对象是成人在线学习者，这些学习者的学习评价不能仅从认知目标进行判断，需要从多个维度全面衡量其学习状态，从而为个性化的学习干预提供支持；另一方面是因为成人在线学习需要强调其交互的发生和交互的质量，要重点考察联通度这一维度。单纯的五个维度无法对学习者的学习进行精确描述和评价，需要对这五个维度进行细化解读，从而真正实现模型的可用性。比如，主动性这一维度需要专家通过系统的文献研究、理论演绎、实践调研来确认哪些指标能够表征。可以看出，五个维度的设计首先来自办学机构对于学习者评价的直观需求，其次来自远程教育领域的相关学习理论，最后来自数据科学的相关研究成果。

(3) 维度表征指标

用什么指标来表征维度是建模过程中的核心难点。从某种意义上说，评价模型从理论上的科学性到实际操作上的可行性需要维度表征指标来承上启下。要解决这一问题，专家需要通过系统的文献研究、理论演绎、实践调研去确认哪些指标能够表征相应的维度。比如，主动性中的自主学习主动性这一指标，从理论逻辑上可以将非强制性学习任务理解为自主学习活动，那么这一类学习任务的参与频次、参与时间、参与效率、相应绩效等都可能作为解读该指标的数据，为保证指标的完备性、有效性，需要用有监督的机器学习或无监督的机器学习进行这一细化指标的专项研究。可以说，每一个维度的提出和指标化都是一项系统研究，只有经历了严谨的研究过程，才有可能真正实现维度的指标化，从而为后续的研发应用提供坚实基础。

(4) 数据支撑

数据支撑是建模过程中的底层基础。“巧妇难为无米之炊”是对这个阶段实际工作的生动描述。要保证模型的科学性和强解释度，在理论建模和维度设计时就需要尽量考虑完备性，但在指标化过程中常常会发现想要的数据并没有足够的支撑。比如，对学习者的参与自主学习活动的时间这一指标，学习平台可能记录了学习者登录和登出的时间点，但对于每一学习活动的时间并没有明确的记录，这就可能需要通过数据埋点

来二次抓取相应数据,这无疑会增加系统的负载。总体来看,有了数据才能够进行相应的学习分析研究和应用,这个问题在今天的在线学习环境中已经得到了很好的解决,但离理想的教育应用还有一定的距离。

2. 综合建模过程中的特征工程

特征工程是对特征变量提取的过程,是从潜在变量中选择具有较好的数据质量并能够支持算法构建的变量的过程。这一过程中主要是根据具体的评价对象及教育学意义的解读,用在线教育领域知识或数据科学的方法来选择、删除或组合潜在变量,进而形成模型中某一具体维度的计算变量。和学习者学习相关的变量非常多,甚至从逻辑上说所有的变量都可能是学习状态的某一表征,但过多的变量会对模型的训练和解读产生极大干扰,会造成模型的过拟合以及教与学解读困难,因此,需要开展特征工程,以最优的方式保证模型的训练和计算效率,并支持教育决策。

3. 模型构建中的应用迭代

模型构建并不能一蹴而就。郑勤华等人构建模型时经历了特征工程、理论建模、实践应用的多轮迭代,在第一轮建模后,开发基于评价模型的工具,并嵌入实践机构的教与学应用。实践反馈了三个方面的问题:一是评价的准确性,如基于模型的评价分值和教师的主观感受有一定的差异;二是评价模型的解释性,如教师对于联通度这一概念普遍不太理解;三是模型指标维度权重确定困难,因为在部分的模型应用中,教师或管理人员拥有调整权重的权利,反而在一定程度上让其无所适从。

这三个方面的问题有些是模型设计尤其是算法设计中的必然问题,需要根据实践应用效果调整某些参数,以使评价的准确性提升;有些是认识问题,需要增加模型的可阅读性;有些是工具开发中的问题,在此不再赘述。总之,模型构建的过程是一个多主体参与、理论联系实际的多轮迭代过程,也是一个不断精准支持教学应用的过程。

在其他应用场景下的学习者模型构建的方法与这里介绍的评价类模型的方法是一致的。首先要回答关于模型构建的核心问题——评价对象、评价维度、维度表征指标、数据支撑,必要时可支撑理论模型的构建;其次要完成特征工程,即选取特征变量,要求特征变量可支撑算法模型构建;最后要模型迭代。

(四) 基于领域知识和数据科学结合的学习者建模应用场景

从学习者模型能够解决教与学中哪些问题的角度,可以将学习者模型的研究与应用分为三个场景进行讨论:统计性分析与评价、学习情绪与专注度监测、能力与知识追踪。

1. 统计性分析与评价

学习分析过程就是围绕学习者模型对学习行为大数据进行分类、整理与呈现,因此,学习者模型在教与学中最基本的功能即实现对学生行为大数据的统计性分析与

评价。典型作用有：实时获取学习者评价数据和阶段评价数据；对知识点覆盖情况、知识点能力层级、个体与班级对比情况等进行可视化；形成直观的、系统化的报告，并结合系统的诊断库为报告反映的问题提供诊断和指导。

2. 学习情绪与专注度监测

随着表情识别技术及可穿戴设备在教育中的应用，学习者的学习情绪与专注度能够受到更好的监测。

基于课堂采集的师生视频数据，可以利用计算机视觉分析技术对学习者的多个维度的实时情绪测量，如高兴、沮丧、生气、惊讶等。结合教师方面的数据，也可以分析教师在课堂上的情绪饱满度，评估教师在不同情绪下授课所实现的学习效果。

除视频与图片信息外，可以利用可穿戴设备(如智能手表、皮肤电传导手环、智能眼镜等)对学习者的行为数据进行采集。例如，额头和上眼睑的变化通常可以表示短时间内的混乱与挫折感，而嘴部的放松可以表示积极学习的情绪。

可穿戴设备通常会配备多个传感器，包括三轴加速度传感器、角速度传感器及心率传感器等；在此基础上，利用特定的机器学习算法，可以较准确地识别学习者在课堂中的举手、记录笔记、起立回答问题等行为。

基于已经识别的学习行为，利用现有的学习科学理论和数据标注方法，综合考量不同类别的行为，进而判断学习者当前的学习专注度与学习情绪。

3. 能力与知识追踪

在智能教育系统中，学习者模型帮助系统对学习者的能力与知识掌握状态进行准确区分与量化。例如，计算机自适应测验(CAT)提供基于被试能力的题目，应用于GRE/GMAT考试；智能教学系统(ITS)提供个性化学习与练习内容，包括Knewton、智慧学伴等；人工智能领域中知识推理的各类模型，如贝叶斯网络，被大量应用于知识追踪问题，用于计算学习者掌握给定知识点的概率。

基于领域知识的学习者建模首先要依据领域知识进行理论建模，同时领域知识在算法建模过程中也发挥着重要作用。不同领域知识指导建立的学习者模型对学习者发展的不同阶段、不同层面发挥着重要作用。基于领域知识的学习者建模是一个庞大的系统，未来如果能建立起基于领域知识的学习者模型系统，学习分析技术则可在学校教育中发挥重要作用。

三、学习者个性化学习方案的推荐方法

个性化学习方案的推荐能够有效解决学习者在线学习迷途问题，从而实现对学习者在线学习的动态指导与监控。个性化学习方案的推荐方法包括个性化学习资源推荐、个性化学习伙伴推荐、个性化学习路径推荐以及个性化学习行为监管。

(一)个性化学习资源推荐

1. 基于推荐算法的个性化学习资源推荐

常用推荐算法包括基于内容的推荐、协同过滤推荐及混合推荐等。基于内容的推荐算法通过识别和提取资源内容的特征来构建学习者特征模型和资源特征模型,将两者匹配度较高的学习资源推荐给学习者。协同过滤推荐算法通过对学习者偏好的挖掘,基于不同的偏好对学习者的进行分组,并将相似的学习资源推荐给各组。协同过滤推荐算法能有效降低模型构建的复杂性,但存在矩阵稀疏和冷启动等问题。混合推荐算法将资源内容特征与学习者特征联合考虑,根据学习者的学习风格和习惯为学习者推荐学习资源。总的来说,保证资源推荐模型构建的合理性和科学性一直是传统推荐算法应用于个性化学习资源推荐的难题。

2. 基于机器学习的个性化学习资源推荐

随着机器学习在计算机视觉、语音识别等领域成功应用,其在在线教育领域的应用也逐渐成为研究热点。许多学者致力于降低学习资源推荐过程的模型依赖性,发挥历史学习数据对资源推荐过程的服务作用,开展将机器学习应用于个性化学习资源推荐的研究工作。韦辛等人通过测试学习者状态与挖掘服务器日志来识别学习者的学习风格与习惯,开展个性化资源推荐研究^①;艾赫等人利用半监督机器学习及历史数据,较为准确地为学习者推荐了课程^②;巴图什等人提出一种基于无监督机器学习的教学资源推荐方法,采用改进的人工神经网络获得了较为合理的推荐结果^③;赵蔚等人提出了知识推荐技术与本体技术相融合的个性化资源推荐策略^④;文孟飞等人采用了一种支持向量机与深度学习相结合的方式来实现网络教学视频推送服务,提升了教学视频资源的利用率和获取率^⑤;塔鲁斯等人构建了一种本体与序列模式挖掘相结合的混合知识推荐系统,为在线学习者推荐个性化资源^⑥;另有研究者提出了基于LSTM神经网络的在线学习路径推荐策略^⑦。

① Vesin B., Ivanovic M., et al., "E-Learning Personalization Based on Hybrid Recommendation Strategy and Learning Style Identification," *Computers in Education*, 2011(3), pp. 885-899.

② Aher S. B., Lobo L. M., "Combination of Machine Learning Algorithms for Recommendation of Courses in E-Learning System Based on Historical Data," *Knowledge Based Systems*, 2013(1), pp. 1-14.

③ Batouche B., Brun A., Boyer A., et al., "Unsupervised Machine Learning Based on Recommendation of Pedagogical Resources," *European Conference on Technology Enhanced Learning*, 2014(9), pp. 548-549.

④ 赵蔚、姜强、王朋娇:《本体驱动的e-Learning知识资源个性化推荐研究》,载《中国电化教育》,2015(5)。

⑤ 文孟飞、胡超、于文涛:《一种基于特征提取的教育视频资源推送方法》,载《现代远程教育研究》,2016(3)。

⑥ Tarus J. K., Niu Z., Mustafa G. M., et al., "Knowledge-Based Recommendation: A Review of Ontology-Based Recommender Systems for E-Learning," *Artificial Intelligence Review*, 2018(1), pp. 21-48.

⑦ Zhou Y., Huang C., Hu Q., et al., "Personalized Learning Full-Path Recommendation Model Based on LSTM Neural Networks," *Information Sciences*, 2018(2), pp. 135-152.

(二)个性化学习伙伴推荐

移动互联网的发展使海量学习资源可以随时随地获取,但学习者在学习过程中难以及时有效交流,这种分散性、封闭的自学模式易催生学习孤独感,导致学习者的学习热情、学习效率与学习质量都有所下降。学习者画像功能可以将具有相似学习背景与共同兴趣爱好的学习者组织在一起,建立一个合作、共享的学习社区,通过交流讨论有效提高学习的积极性,改进学习效果。因此,可以基于学习者画像呈现的不同学习风格与偏好兴趣为学习者推荐特点相似或风格互补的学习伙伴。此外,基于学习者画像还可对学习者的兴趣方向进行判定,从而为其推荐同一层次、同一专业的学习伙伴。同时,通过分析学习者画像记录追踪的学习迁移轨迹,可以向学习者推荐具有相同学习行为的同学,如访问相同学习资源、检索相近关键词、下载近似资料的学习者。

(三)个性化学习路径推荐

个性化学习路径推荐是指围绕学习者的个性化学习目标、学习需求与学习风格来为学习者设计最佳学习方案。根据学习者画像的动态迭代更新,可以分析出学习者的即时学习兴趣,结合其学习风格和行为特征,能够预测其下一步的学习内容,从而提供个性化的课程路径导航服务。具体而言,可根据学习者画像挖掘学习者个性化学习特征和学习媒介平台的资源属性(每个平台具有主题分类、知识点标注、知识点难度、测评类型等属性标注),同时借助语义关联技术分析学习资源间的内在关系,由此得出学习者已有的知识储备和新的学习内容之间的关系,从而为其提供个性化适应性学习策略。需要指出的是,由于学习者的教育背景、研究层次和认知能力不同,学习路径在推荐形式上呈现出多样化、复杂化及非连续性等特征。因此,提供推荐服务需要充分结合学习者的学习特征,对其画像进行动态修正,以此保证学习路径与学习者的目标内容、学习方式相匹配。

(四)个性化学习行为监管

在拥有海量资源的网络中,在线学习者获取学习资源的便捷性得到大幅提高,但同时存在知识供求关系不均衡的问题。换言之,个性化学习缺乏有效的监管,学习者自我监管能力的缺乏会导致学习行为散漫、学习效率低下,造成学习资源的极大浪费,这也是长期阻碍个性化学习效果提升的主要问题。大数据深度画像可以为学习者提供及时、高效、有针对性的个性化学习监督服务,能够在较大程度上降低学习过程中的沉淀率与辍学率,从而提升学习者的学习自主性。具体而言,将消极学习的行为检测作为个性化学习监管的前提,为在线学习者的学习任务和学习行为设置最低目标值;同时通过构建学习者画像模型追踪并记录画像的更新变迁,及时掌握学习者的学习进

程和当前存在的问题。当低于目标值时，系统有针对性地给出学习预警，如当在线讨论参与次数少于两次时，可认定学习者该周期的在线学习行为存在消极现象，系统及时提供适合学习者学习风格的个性化干预方案，尽量减少辍学和停滞行为的发生，提高学习效率和质量。

四、个性化在线学习服务案例

个性化在线学习是在线教育大数据应用服务的主要阵地，各类个性化在线教育平台能够采集学习者在线学习过程中的行为数据，并对学习者的学习兴趣、知识水平、学习风格、学习进度等做出分析和预测，以提供个性化的在线学习服务。

案例 5-1

个性化在线学习企业 Knewton 并没有创建内容或建设自己的平台，而是与其他学习公司(如培生、霍顿·米夫林、麦克米伦等)合作，为它们提供 Knewton 引擎，以强化学习应用程序。Knewton 将数据科学、统计、心理测量、内容图表、机器学习、标签技术和基础设施整合在一起，以实现大规模的个性化学习。Knewton API 与其他公司产品有着千丝万缕的联系，可以为数学等学科领域提供自适应学习环境。Knewton API 是连接应用场景与合作平台的桥梁，以云服务的方式由第三方企业调用，如图 5-11 所示。




图 5-11 Knewton API

请结合上述框架，查阅关于 Knewton 的相关资料，思考 Knewton 的自适应学习服务有哪些，以及这些自适应学习服务如何为学习者提供个性化在线学习服务。

案例 5-2

北京师范大学未来教育高精尖创新中心的智慧学伴是基于学科素养、学科能力、大数据技术及人工智能技术研发的智能公共服务平台。平台为中小學生提供在线测评，可以诊断学科素养、学科能力，提早发现学科优势和学科问题，推送个性化报告与学习资源，提供一对一在线教师辅导和学习伙伴等服务。平台帮助教师适应教育改革，提升精准个性化教学能力，指导教师发现学科特长生，帮助学习困难学生解决问题，使教师在提升课堂教学质量的同时快速适应教育改革方向。平台帮助家长动态掌握孩子的学习表现、学科优势与学习问题，了解孩子的个性特点，从而使孩子的成长变得轻松，减轻家长的压力。总而言之，平台通过大数据采集、分析、预测等功能为学校、教师、学生和家长提供个性化的智能教育服务。

请查阅更多关于智慧学伴平台的资料，如学术论文、新闻报道等，思考该平台能够采集学习者哪些方面的数据，以及基于这些数据平台如何为学习者提供个性化的在线学习服务，并画出实现流程图。



教学活动建议

本节教学的重点是个性化在线学习服务的实现流程、基于领域知识和数据科学结合的学习者建模、学习者个性化学习方案的推荐方法；难点是基于领域知识和数据科学结合的学习者建模。建议教师采用视频资源和案例分析相结合的方式进行授课，侧重于引导学习者深刻理解大数据技术在实现个性化教学服务方面的潜力。

本节内容的目的是让学习者理解基于大数据的个性化在线学习服务，包括实现流程、学习者建模及推荐方法，并能对典型的个性化在线学习服务应用案例进行分析。



学习活动建议

本节涉及跨学科的知识，建议充分利用网络，咨询大数据技术、教育技术领域专家，并以小组合作的形式广泛调研，分析个性化在线学习服务应用的其他案例，全面理解基于大数据的个性化在线学习服务的基本原理。

第三节 基于大数据的精准在线教育管理与质量监测

一、精准管理与质量监测的目标与方法

在线教育管理与质量监测是提升在线教育质量的一种手段，尤其是在大数据、人工智能等技术不断发展成熟的大背景下，其逐渐成为促进在线教育发展的一把利器。这里重点阐述在大数据支持下的精准在线教育管理与质量监测的目标以及实现这一目标的方法。

(一) 基于大数据的精准在线教育管理与质量监测的目标

1. 实现个性化服务

在线学习环境给予了学习者充分的自主权，学习者可以自主决定学习速度，选择感兴趣的学习资源和学习活动等。然而，学习者常常面临“接下来学什么”的问题，导致信息迷航、认知过载。在线教育的发展，尤其是大数据技术、人工智能技术赋能教育实践的不断深入，使大规模个性化学习的实现成为可能。通过采集、分析和处理学习者全流程的在线学习行为和学习过程数据，可以对学习者的知识学习能力进行精准诊断，并根据诊断结果为学生提供旨在提升知识水平的个性化学习服务。同时，在智能技术和装备的加持下，捕获、识别和分析学习者的个性化学习需要变得更方便容易，并且能根据学习情境的变化动态调整和推送满足学习者情境化需要的个性化服务。最终，在个性化学习理念与智能技术深度融合发展的过程中，实现为在线学习者提供千人千面的学习服务。

2. 实现教育质量动态监测

在线环境中，数据每天都产生与流动，使得教育质量监测变得开放、公开、透明，并且具有动态性。在线考试数据、测评数据及作业过程数据等教育质量监测数据实时地汇聚于教育质量监测系统中，将阶段性、静态的调查转变为全过程、动态化的监测。进一步，基于教育质量监测数据，利用教育建模技术构建教育质量监测模型，通过实时、综合分析来动态监测学习者的学习过程及质量，进而形成科学有效的教育质量监测报告及问题解决方案，最终实现教育质量动态监测。

3. 实现科学化教育决策

在线教育的发展积累了海量的教育数据，这为教育的科学化决策提供了强有力的

技术支持。对于教育管理部门而言,通过对在线教育管理系统采集、汇聚的各类数据(如各类教育事业发展统计数据、在线教育培训机构办学数据等)进行深度挖掘、分析与建模,在综合应用多种模型与数据的基础上,能够获得针对在线教育发展状况的多种决策路径与决策建议。对于教学者而言,可以利用大数据技术分析在线教学系统中的学习者全过程学习数据(如学习交互数据、学习投入数据等),绘制学习者画像,深度挖掘学习者在学习过程中的问题,进而做出较为科学的教学干预,促进师生共同发展。总体而言,建立“用数据说话、用数据决策、用数据管理、用数据创新”的机制,可以有效提高教育教学决策水平的针对性与科学性。

(二) 目标的实现方法

大数据技术、方法的先进性为复杂目标的实现提供了支持。整合多维数据是基础,采用可视化方式动态、直观地展现数据,进而开展全过程数据的实时监控,最终实现个性化服务、科学化决策与质量动态监测。

1. 开展多维数据整合

以往单维或单一模态的数据仅能提供部分过程信息,会降低数据分析结果的准确性,而真实的教育或学习过程往往是复杂多维的,可能是多平台、多场所、多方式的混合。随着数据采集技术的不断发展成熟,获取的数据也越来越丰富、越来越多元,整合声音、视频、图片、文本、生理、心理等多维度、多模态的数据对于精准在线教育管理与质量监测具有重要的现实意义。现行的整合方式主要有:①多对一,即用多维度、多模态的数据表征一个测量指标,以提高测量的准确性,如用声音数据和表情数据表征情感;②多对多,即用多维度、多模态的数据表征多个测量指标,以提高信息的全面性,如同时用眼动数据表征注意力,用脑电数据表征认知。^①多维数据整合的价值体现在提高在线教育管理的精准性和质量监测的准确性,为个性化服务、科学化决策与质量动态监测的实现提供基础方法支持。

2. 采用可视化方式呈现

尽管已经有先进的大数据挖掘与分析技术帮助管理者、教师及学习者依据大量的数据分析得出结果,但要在纷繁复杂的数据中获得对相关信息的全面、正确、深入理解,这些技术则远远不够。数据可视化为在线教育大数据的创新应用提供了一个展示的窗口。当下,各类数据大屏、数据驾驶舱都以数据可视化的方式展示数据分析结果,为不同群体的决策发挥关键性作用。在线教育管理与质量监测亦是如此,通过数据采集与预处理、可视化表征、创建模型与验证假设、获取知识等数据可视化分析的操作

① 穆肃、崔萌、黄晓地:《全景透视多模态学习分析的数据整合方法》,载《现代远程教育研究》,2021(1)。

流程^①，再辅以基于传统可视化图表的展示、基于地图的展示、基于传统可视化图表与地图相结合的展示以及基于数据流的拓展展示模式^②呈现数据分析结果，让管理者及教师明确教育教学的问题所在，辅助科学决策，同时让学习者获得清晰的自我认知，支持其个性发展。

3. 基于全过程数据的实时监测

全过程数据的实时汇聚为监测学习者的学习情况与教育质量提供了便利。在监测在线学习者的学习方面，在线教学平台获取的在线时长、交流讨论次数、在线活跃度、在线交互等学习行为过程数据可以通过可视化的方式呈现，也能够清晰呈现在线学习者的学习结果，还能展现实时的学习变化情况。针对这些数据结果，在线教学平台能够自动推送个性化学习资源，一定程度上满足学习者对个性化学习服务的需要。在教育质量动态监测方面，教育质量监测系统能够可视化地展示不同区域、学校的教育质量结果，并以汇入的动态数据为基础，实时、动态地展现教育质量的变化情况，如横纵对比的教育质量监测结果，进而达到动态监测的目标。

二、基于大数据的精准在线教育管理体系的实现路径

在大数据时代，学生、教师、家庭、企业等主体产生的教育数据和教育需求愈加多样。当前我国教育正从管理向治理转型，这种转型不仅体现在学校这一微观层面，而且体现在整个教育系统(含在线教育)的科学化、精细化、个性化发展方向上。教育管理向教育治理的转型不是简单的升级技术，也不是仅将数据收集起来进行可视化呈现。实现基于大数据的精准在线教育管理要立足于整个教育系统的转型，支撑教育管理系统的底层架构和流程必须在技术升级的基础上进行解构和重组，从而适应新的教育变革。具体而言，构建基于大数据的精准在线教育管理体系需要从制定规划、组建团队、搭建平台、汇聚数据、深化应用、机制保障六个策略方向进行考虑，如图 5-12 所示。

(一)因地制宜，制定规划

需求是基于大数据的精准在线教育管理的出发点，决定了在线教育管理是否指向真正的教育问题。教育需求具有区域特征，不可千篇一律或照搬成功经验，需要因地制宜地制定各类规划，从战略规划、任务规划、工作规划三个层面进行推动。在区域

^① Keim D. A., Mansmann F., Schneidewind J., et al., "Visual Analytics: Scope and challenges," *Visual Data Mining*, 2008(4), pp. 76-90.

^② 杨现民、郭利明、邢蓓蓓：《区域教育大数据分析架构与展示设计研究——以江苏省 A 市为例》，载《电化教育研究》，2020(5)。




图 5-12 基于大数据的精准在线教育管理体系

精准在线教育管理的战略规划层面，需要设计复合方案，面向区域内各教育主体进行持续的需求采集，充分整合多方治理目标，依据社会需求进行规划，统筹区域内不同类型、不同层级教育主体之间的统一性需求和个性化需求。在任务规划层面，需要确认区域精准教育管理的总目标及子目标，分解达到项目目标所需完成的任务单元，确保目标与需求之间环环相扣。在工作规划层面，需要结合实际精准教育管理的条件和周期，分析各级目标的完成难度，明确工作进程，提高基于大数据的精准教育管理的效率，从而保证精准教育管理紧扣区域本身迫切的、真实的需求目标。一般而言，可以将需求归为四类：一是描述性的需求，强调借助大数据技术，将教育的全貌用可视化的方式展现；二是诊断性的需求，强调在全貌展示的基础上进行价值判断，并发现问题；三是预测性的需求，强调在诊断的基础上对未来发展态势进行研判和预测；四是干预性的需求，强调在预测的基础上找出关键要素和节点，发现干预的着力点和干预建议。

(二)学科融合，组建团队

在基于大数据的精准在线教育管理的各项任务目标确立的基础上，应考虑负责团队必备的各项能力，将其与各类学科专业进行匹配，实现“专人做专事”。在完整的基于大数据的精准在线教育管理方案中，应该至少配备教育教学团队、教育管理团队、专家咨询团队及教育技术团队，以确保所遵循的教育理论的科学性和工作落地的可行

性。教育教学团队对接在线教育场景与教育需求,设计精准的在线教育管理方案,并反馈效果。教育管理团队搭建全流程数据服务体系,根据分析需求设计数据存储逻辑,维护并管理数据。专家咨询团队论证精准在线教育管理方案与科学教育理念、区域教育政策的一致性,避免发生根本性错误。教育技术团队作为方案的推动者,串联各环节的需求及成果,提高机制运行的效率,不断优化团队协作和平台功能。其中,教育技术团队以交叉学科人才的身份,以各自的专业术语与其余三个团队积极对话,尽量避免由高成本沟通或专业差异导致的纰漏,发挥至关重要的作用。

(三)数据中心,搭建平台

数据中心平台是实现科学化精准在线教育管理的主轴,是保障整个在线教育治理系统稳定运行的技术关键。大数据时代精准在线教育管理的基础是依托各种类型的数据,利用教育信息化系统,通过大数据分析、人工智能、云计算等技术,实现人、财、物更加高效的配置和管理,实现科学、智能、高效的管理、决策和服务。数据中心的精准在线教育管理平台应该包括两个基本平台:数据治理平台和综合应用平台。数据治理平台解决各信息系统联通问题,对数据进行统一标准的集中管理,打破数据孤岛现象,具有统筹作用。综合应用平台面向实际的精准在线教育管理方案,链接应用方案与教育问题,形成基于数据的中央管理系统。综合应用平台能更直接地对应各类在线教育场景的需求,同时也为现阶段的新需求提供对照,促进全流程的持续改进。

(四)多维分层,汇聚数据

清晰、多维、全面的数据是精准在线教育管理的基础。精准在线教育管理中多维数据库的建立依靠线上线下多种汇聚方式,形成层次性强、数据种类全、数据质量高的结构化数据采集和存储方案,保证数据能够支撑教育管理方案的落实。区域各类统计数据往往具有系统性和概括性。教育管理数据来自不同教育机构的人员、物资等,能够进一步说明资源的配置和使用情况。教育教学数据直接来自教学流程,是对教学质量的直接反映。此外,因为教育本身离不开经济、社会等复杂因素之间的关联,这些因素往往对精准在线教育管理的方案制定起到关键性作用,所以还应该综合教育系统之外的环境数据。值得注意的是,数据采集及处理作为基础性工作,耗时较长,所得数据体量庞大,因此,需要制定精准的数据规范和流程以提升数据质量水平。

(五)建立模型,深化应用

基于大数据的教育建模决定了精准在线教育管理在应用层面的高度和深度,是数据推动科学化教育管理的根本基础。为建立科学化教育管理机制,平台及数据所提供的信息需要进行深层次加工,从而挖掘简单现象背后的复杂原因:在教育建模相关理

论指导下，为各类在线教育场景提供模型支撑，更加长远地服务于精准在线教育管理；为相关学术理论提供实证，丰富或调整学理逻辑，助力各项教育研究成果落地；使教育模型与教育管理系统对接，辅助在线教育教学的质量检测、绩效评估、学业预警等工作。在在线教育教学应用环节，需要定向、定点、即时地获取实施效果的反馈，不断迭代更新，以适应未来教育需求。

(六) 标准规划，机制保障

规范化的数据治理流程是精准在线教育管理长久运行的保障。规范化的数据治理流程应摆脱对系统硬件设施使用的简单描述，而应站在系统的高度为各个环节提供实施标准。除规范化治理流程外，还需要完善各类保障机制：优化数据流转机制，统一数据标准，划分权限及监管职责，保障数据交换工作的有序进行；建立安全保障机制，坚持以人为本、以学生个性化发展为首，遵循数据伦理，推进数据隐私的技术保护和法律法规保障；完善配套教学改革机制，充分考虑在线教育系统的复杂性，从政策层面为在线教育质量的提升保驾护航，避免大数据时代下的精准在线教育管理成为“技术孤岛”。

三、基于大数据的精准在线教育管理与质量监测服务案例

基于大数据的精准在线教育管理与质量监测是实现在线教育智能管理与服务的重要途径。教育智能化管理和服务的基础是依托各种类型的数据，利用教育信息化系统，通过大数据分析、人工智能、云计算等技术，实现对人、财、物更加高效的配置和管理，实现全方面的科学、智能、高效的管理、决策和服务。这里围绕动态监测教育过程、把控教育现状、辅助教育决策以及助力优质教育资源共享四个方面的案例，展现精准在线教育管理与质量监测服务因技术的介入而变得更加科学和高效。

案例 5-3

“智慧线”在线学习分析云平台是由北京师范大学远程教育研究中心开发的在线教育数据分析平台。“智慧线”的核心功能是挖掘在线教育机构日常教学和管理数据的价值，通过对数据的汇聚、建模、分析和可视化为机构用户提供精准管理的数据支持，帮助用户监测机构运行、发现深层规律、预警潜在风险，进而优化工作和管理效率。

作为在线教育大数据服务平台，“智慧线”首先通过数据抽取工具抽取汇聚在线教育机构使用的应用系统中的数据，核心是体现教学行为和管理行为的动态数据。作为在线教育大数据服务平台，“智慧线”还需要使用数据 ETL(extract-transform-load)工具，抽取并汇聚机构基本信息、静态教学与管理行为和动态教学与管理等数据，

能够动态表征机构管理与教学状况的数据是汇聚的重点。数据汇聚后通过数据清洗和标准化,将不同来源、不同类型的数据加以整合,并存储至数据仓库。数据分析师则基于汇聚的数据来构建针对机构的定制评价、预测模型。基于构建的数据模型,机构可以获得教学与管理状况的分析结果。这些分析结果会以数据分析报告的形式通过 web 端或移动终端(智能手机软件)定向推送给用户,不同角色的用户将收到与其业务相关的数据分析报告,如招生部门会收到招生数据分析报告,教师会收到教学报告,决策者会收到机构工作综合分析报告。

思考:该平台能够采集哪些数据?提供服务的基本流程是什么?如果要用该平台监测一个在线学习者的学习发展状况,具体的思路是什么?

案例 5-4

区域教育大数据展示大屏能够可视化呈现区域内的教育主体规模、办学条件、教育经费投入、教育信息化建设、教育信息化应用的情况。在教育主体规模方面,对学校的规模、分布、性质、所属学段等信息进行分析,对教师的规模、性别比例和教龄等情况进行归纳,对学生的规模、性别比例和分布进行刻画,呈现出区域教育规模的基础信息。在办学条件方面,分学段对建筑面积、教学及辅助用房面积、体育活动场地面积、绿化面积等核心办学条件指标进行展示。在教育经费投入方面,按照不同的学段和公办民办的分类进行经费投入统计。在教育信息化建设方面,分别统计存储容量、累计资源数量、人均上线时长和共享数据次数等指标。在教育信息化应用方面,通过大数据计算,按学段、学科和用途维度分类统计网络应用的人数和时长。区域教育大数据展示大屏可全面反映区域的教育资源需求、教育资源分布、教育信息化建设和教育信息化应用的关系。

查找更多教育大数据展示大屏的应用案例,思考:对于教管理者而言,这些教育大数据展示大屏为什么能够把控一个地区或一个学校的整体教育状况,其背后的逻辑是什么?

案例 5-5

北京市基础教育资源配置政策模拟平台是由北京师范大学基础教育大数据应用研究院“宏观教育综合评价与决策支持平台”研究团队开发、维护的平台。该平台的基本功能包括现状分析、人口情景预测、人口—教育系统耦合及政策模拟,在应用方面具有公共服务和个性化定制两方面的优势:一是公共服务,即提供平台,用户输入基础数据,自行设置相关政策变量,得到对关键教育资源配置指标的情景分析结果;二是个性化定制,即用户若对相关产品感兴趣,可以定制管理信息系统,用户

提供详细的人口普查数据、近年学校统计数据以及相关资源，据此开发决策支持系统，帮助进行情景预测；同时也可以根据用户要求，给出不同政策取向下的教育管理政策建议。

登录北京市基础教育资源配置政策模拟平台，查看平台相关信息，思考：该平台是从哪些方面、用哪些数据对北京市整体及各区县进行教育资源配置模拟的？还能从哪些方面进行教育资源配置模拟？数据该如何采集？

案例 5-6

百度教育大脑 3.0 是将数据挖掘和人工智能技术应用于教育行业的系统平台。基于百度教育大脑 3.0 的三大核心能力——教育知识图谱、教育用户画像、教育数据智能，百度智慧课堂能够串联、匹配优质教育资源，有效提高教育资源流通效率，推动区域化教育资源共享。针对区域教育资源难以互通的问题，百度智慧课堂构建网络学习空间，以个人空间、教学空间、区校空间的形式帮助教师实现云端资源管理，协助学校积累校本资源，从而实现区域教育资源优势互补。

基于以上的介绍，查阅更多关于百度智慧课堂的应用案例，思考：百度智慧课堂为何能帮助解决区域优质教育共享的问题，其背后的逻辑是什么？

教学活动建议

本节教学内容的重点是精准管理与质量监测的目标与方法、基于大数据的精准在线教育管理与质量监测服务的案例，适合以案例分析为基础的学习。建议教师采用专家报告、视频资源与小组合作相结合的方式进行教学，带领学习者深入分析精准教学管理与质量监测服务的各类典型案例，鼓励学习者思考案例中的方法进一步应用的可能。

学习活动建议

本节的内容与创新实践结合得非常紧密。建议努力深入教材提及的每个典型案例，以小组合作的方式分析各种创新实践的原理，并进一步思考这些原理是否可以拓展到其他教育问题领域。

自我评价

一、学习经历评价

1. 你是否阅读了第五章的所有内容？

建议：如果答案为“否”，请暂停自我评价，阅读未读过的部分。

2. 你能否理解第五章的所有内容?

建议: 如果答案为“否”, 请首先列举不理解的内容, 然后尝试利用以下方法解决遇到的问题。

- ①利用图书馆和网络资源, 查找相关文献。
- ②与同学进行讨论。
- ③向教师提问, 争取教师的帮助。
- ④将问题发布在线上讨论区, 争取更多人的帮助。

二、自测题

1. 列举在线教育数据采集的技术和方法, 并选择一种工具对其应用场景做简要说明。列举在线教育数据的存储方式。

在线教育的数据采集技术有: _____、_____、_____、_____和_____。方法有: _____、_____和_____。

在线教育数据采集工具的应用场景为: _____。

在线教育数据存储方式有: _____、_____、_____和_____。

2. 列举在线教育的数据清洗与整合工具, 并选择一种数据清洗或整合工具进行体验。

在线教育的数据清洗工具有: _____、_____、_____、_____等。

在线教育的数据整合工具有: _____、_____、_____等。

3. 简述个性化在线学习服务的实现流程, 并举一个案例进行说明。

4. 简述基于领域知识和数据科学相结合的学习者建模的流程、方法及应用场景。

5. 列举学习者个性化学习方案的推荐方法, 并尝试用案例进行简要说明。

方法一: _____。案例一: _____。

方法二: _____。案例二: _____。

方法三: _____。案例三: _____。

方法四: _____。案例四: _____。

6. 简述在线教育管理与质量监测的目标、内容, 并通过一个案例对基于大数据的精准教育管理与质量监测进行说明。



推荐阅读文献

[1]姜强, 赵蔚, 王朋娇, 王丽萍. 基于大数据的个性化自适应在线学习分析模型及实现[J]. 中国电化教育, 2015, (1): 85-92.

[2]潘玮, 牟冬梅, 李茵, 刘鹏. 关键词共现方法识别领域研究热点过程中的数据清洗方法[J].

图书情报工作, 2017, 61(7): 111-117.

[3]孙洪涛, 郑勤华. 教育大数据的核心技术、应用现状与发展趋势[J]. 远程教育杂志, 2016, 34(5): 41-49.

[4]孙立伟, 何国辉, 吴礼发. 网络爬虫技术的研究[J]. 电脑知识与技术, 2010, 6(15): 4112-4115.

[5]王曰芬, 章成志, 张蓓蓓, 吴婷婷. 数据清洗研究综述[J]. 现代图书情报技术, 2007, (12): 50-56.

[6]文孟飞, 胡超, 于文涛, 刘伟荣. 一种基于特征提取的教育视频资源推送方法[J]. 现代远程教育研究, 2016, (3): 104-112.

[7]吴砥, 饶景阳, 吴晨. 教育大数据标准体系研究[J]. 开放教育研究, 2020, 26(2): 75-82.

[8]杨现民, 田雪松, 等. 中国基础教育大数据 2016—2017: 走向数据驱动的精准教学[M]. 北京: 科学出版社, 2018: 74-83.

[9]杨现民, 田雪松. 互联网+教育: 中国基础教育大数据[M]. 北京: 电子工业出版社, 2016: 113-115.

[10]赵蔚, 姜强, 王朋娇, 王丽萍. 本体驱动的 e-Learning 知识资源个性化推荐研究[J]. 中国电化教育, 2015, (5): 84-89.

[11]郑勤华, 陈耀华, 孙洪涛, 陈丽. 基于学习分析的在线学习测评建模与应用——学习者综合评价参考模型研究[J]. 电化教育研究, 2016, 37(9): 33-40.

[12]郑勤华, 孙洪涛, 陈耀华, 刘春萱. 基于学习分析的在线学习测评建模与应用——综合建模方法研究[J]. 电化教育研究, 2016, 37(12): 40-45.



基于大数据的个性化在线学习服务



基于大数据的精准在线教育管理与质量监测